

1 Jl. Raya Telang

East



Street View

Feb 2025 - See more

Semester Gasal 2025-2026

Supervised Learning




Course Information

- Course Title : Machine Learning / “*Pembelajaran Mesin*”
- Course Code : ML-IF 101
- Semester : 2025-2026 (1)
- Credits : 3
- Instructor : Dr. Cucun Very Angkoso, MT
- Email : cucunvery@ieee.com
- G-Classroom : (B) zmgrvfgc / (C) mzybgy6d

next slide →

Kontrak Kuliah


- Perkuliahan dimulai 07.30 wib ~ Max Jam 08.15wib
- Wajib bergabung G-Classroom
- Penilaian akhir
 - UAS : 30%
 - UTS : 30%
 - Tugas : 40%
- Absensi : threshold 80%, 20% tidak hadir tanpa keterangan
 - $20\% \times 16 \text{ Pertemuan} = 3,6 \sim 4 \text{ pertemuan}$
 - 4 pertemuan tidak hadir tanpa keterangan = Tidak berhak mendapat penilaian akhir.





“Regression Techniques”

Linear regression, polynomial regression, and evaluation metrics






Pendahuluan

- Regresi adalah jenis metode **supervised learning** yang digunakan untuk memprediksi nilai kontinu.
- Contoh:
 - Memprediksi harga rumah
 - tren pasar saham
 - prakiraan suhu.
- Tujuan: Untuk memodelkan hubungan antara variabel dependen (target) dan satu atau lebih variabel independen (prediktor).

Regresi

- Dalam hal ini, perkiraan hubungan variabel tersebut digunakan model matematis untuk melihat bagaimana bentuk hubungan antar variable tersebut.





Simple Linear Regression

Konsep regresi linier berusaha menemukan garis lurus yang terbaik untuk menjelaskan hubungan antara dua variabel. Dalam regresi linier, variabel independen diplot pada sumbu x dan variabel dependen diplot pada sumbu y. Regresi linier kemudian mencoba untuk menarik garis lurus terbaik (yang disebut sebagai "garis regresi") yang dapat menunjukkan hubungan antara kedua variabel tersebut.

$$\hat{y} = b_0 + b_1 X_1$$

Variabel tak bebas


perpotongan y (**konstanta**)

Variabel bebas

Koefisien kemiringan

Simple Linear Regression

- Regresi linier sederhana adalah model regresi yang memperkirakan hubungan antara satu variabel independen dan satu variabel dependen dengan menggunakan garis lurus. Kedua variabel harus bersifat kuantitatif.




$$\hat{y} = b_0 + b_1 X_1$$

berat [t] = $b_0 + b_1 \times$ Berat Pupuk [Kg]
 kentang

$$b_0 = 8[t]$$

$$b_1 = 3\left[\frac{t}{kg}\right]$$


y [ton]
(berat kentang yang didapat)





Simple Linear Regression

- Kuadrat Terkecil Biasa:




$$\hat{y} = b_0 + b_1 X_1$$

b_0, b_1 Sedemikian sehingga nilai dari :

$SUM(y_i - \hat{y}_i)^2 \rightarrow$ Seminimal mungkin

y [ton]
(berat kentang yang didapat)



Linear Regression

Varians

adalah ukuran statistik yang menggambarkan sebaran data atau distribusi data dari nilai rata-rata.

Varians dihitung dengan cara menghitung rata-rata kuadrat jarak antara setiap titik data dengan nilai rata-rata.

Semakin besar varians, semakin besar variasi data dan semakin tersebar data di sekitar nilai rata-rata.

Varians digunakan sebagai alat untuk mengukur seberapa jauh titik data tertentu tersebar dari nilai rata-rata, dan sangat penting dalam statistik inferensial dan pengambilan keputusan berdasarkan data.

$$\sigma^2 = \frac{\sum (X - \mu)^2}{N}$$

Keterangan:

σ^2 : varians populasi

Σ : simbol sigma yang berarti jumlah dari semua nilai

x : setiap nilai dalam populasi

μ : nilai rata-rata (mean) dari populasi

N : jumlah total nilai dalam populasi



Linear Regression

Kovarians

Kovarians adalah ukuran statistik yang mengukur hubungan antara dua variabel acak.

Kovarians menunjukkan seberapa kuat dua variabel bergerak bersama-sama.

Jika kovarians positif, maka kedua variabel cenderung bergerak ke arah yang sama, sedangkan jika kovarians negatif, maka kedua variabel cenderung bergerak ke arah yang berlawanan.



$$\text{Cov}(X, Y) = \frac{\sum (X_i - \bar{X})(Y_j - \bar{Y})}{n}$$

Keterangan:

$\text{Cov}(X, Y)$: kovarians antara variabel X dan Y

Σ : simbol sigma yang berarti jumlah dari semua nilai

X_i : nilai dari variabel X

$\bar{X}$: nilai rata-rata (mean) dari variabel X

Y_j : nilai dari variabel Y

$\bar{Y}$: nilai rata-rata (mean) dari variabel Y

n : jumlah total pasangan nilai dalam data



Linear Regression

Input data

```
x = np.array([1, 2, 3, 4, 5])
```

```
y = np.array([2, 4, 5, 4, 5])
```

#Hitung jumlah data (n)

```
n = len(x)
```

#Hitung rata-rata x dan y ($\bar{x}$ dan $\bar{y}$)

```
xmean=np.mean(x)
```

```
ymean=np.mean(y)
```

Hitung variansi dari x (s^2x)

```
#  $s^2x = (1/n) * \sum(x_i - x_{mean})^2$ 
```

```
#  $s^2x = (1/5) * [(1-3)^2 + (2-3)^2 + (3-3)^2 + (4-3)^2 + (5-3)^2]$ 
```

```
s2x = np.mean((x - xmean) ** 2)
```

Hitung kovarians (s_{xy})

```
#  $s_{xy} = (1/n) * \sum(x_i - \bar{x})(y_i - y_{mean})$ 
```

```
#  $s_{xy} = (1/5) * [(1-3)*(2-4) + (2-3)*(4-4) + (3-3)*(5-4) + (4-3)*(4-4) + (5-3)*(5-4)]$ 
```

```
sxy = np.mean((x - xmean) * (y - ymean))
```

Hitung koefisien regresi (b_1)

```
b1 = sxy / s2x
```

Hitung konstanta (b_0)

```
b0 = ymean - b1*xmean
```

Menampilkan persamaan garis regresi linier

```
print('Persamaan garis regresi linier: y = {:.2f} + {:.2f}x'.format(b0, b1))
```



Multiple Linear Regression

$$\hat{y} = b_0 + b_1X_1 + b_2X_2 + \cdots + b_nX_n$$

Variabel tak bebas

(konstanta)

Variabel bebas 1

Variabel bebas 2

Variabel
bebas n

Koefisien kemiringan 1

Koefisien kemiringan 2

Koefisien kemiringan n

Multiple Linear Regression



$$Potatoes[t] = 8t + 3 \frac{t}{kg} \times Fertilizer[kg] - 0.54 \frac{t}{^{\circ}C} \times AvgTemp[^{\circ}C] + 0.04 \frac{t}{mm} \times Rain[mm]$$





Asumsi pada Regresi Linear

- **Anscombe's quartet (1973)**

Keempat set data Anscombe's quartet terdiri dari sepasang variabel x dan y , di mana x adalah variabel independen dan y adalah variabel dependen. Setiap set data terdiri dari 11 titik data. Ketika dihitung statistik deskriptif seperti **mean**, **variance**, dan **korelasi** antara x dan y , keempat set data ini menunjukkan hasil yang sama.

Namun, ketika keempat set data diplot pada sebuah grafik, kita dapat melihat bahwa masing-masing set data memiliki pola yang berbeda, walaupun memiliki statistik deskriptif yang sama. Sebagai contoh,

- set data pertama memiliki pola linear yang jelas,
- sementara set data kedua memiliki pola quadratic.
- Set data ketiga memiliki pola linear dengan satu titik yang jauh berbeda,
- sementara set data keempat memiliki pola yang hampir sama dengan set data pertama, namun memiliki satu titik yang sangat jauh dari titik-titik data lainnya.



Asumsi pada Regresi Linear

Beberapa asumsi yang harus dipenuhi dalam regresi linier antara lain:


1. Linearitas

(Hubungan antara data Y dan X adalah linier)




2. Homoscedasticity (Equal variance)

Variansi dari nilai X harus sama untuk semua data.




3. Normalitas Multivariat

(Distribusi error adalah normal)



4. Independensi data.

Termasuk “tidak ada autokorelasi”




5. Lack of Multicollinearity

(Prediktor tidak berkorelasi satu sama lain)



6. Pemeriksaan Outlier

(Tidak ada data yang jauh dari nilai tengahnya)



Demo Code



```
from sklearn.linear_model import LinearRegression
```

```
# Load dataset
```

```
data = pd.read_csv("dataset.csv")
```

```
# Pisahkan data menjadi variabel dependen dan independen
```

```
X = data[["X1", "X2"]]
```

```
Y = data["Y"]
```

```
# Membuat Model linear regression
```

```
model = LinearRegression()
```

```
# Melatih model Regresi Linier Berganda pada set Pelatihan  
model.fit(X, Y)
```

```
# Tampilkan nilai koefisien dan intersep (konstanta)
```

```
print("Coefficients:", model.coef_)
```

```
print("Intercept:", model.intercept_)
```

```
# Menampilkan persamaan garis regresi linier
```

```
print('Persamaan garis regresi linier: y = {:.2f} + {:.2f}X1 +  
{:.2f}X2'.format(model.intercept_, model.coef_[0], model.coef_[1]))
```

```
# Prediksikan Y untuk nilai X yang baru (X1 & X2)
```

```
new_X = np.array([[1, 2], [3, 4]])
```



```
predicted_Y = model.predict(new_X)
```

```
print("2 Nilai data [X1, X2] yang akan diprediksi:", new_X[0], new_X[1])
```

```
print("Predicted Y:", predicted_Y)
```

Polynomial Regression

- Suatu bentuk regresi yang memodelkan hubungan variable-nya sebagai polinomial derajat ken.
- Persamaan:
- Kasus Penggunaan:
 - Berguna untuk kumpulan data yang hubungannya tidak linier.





Polynomials	Form	Degree	Examples
Linear Polynomial	$p(x): ax+b, a \neq 0$	Polynomial with Degree 1	$x + 8$
Quadratic Polynomial	$p(x): ax^2+bx+c, a \neq 0$	Polynomial with Degree 2	$3x^2-4x+7$
Cubic Polynomial	$p(x): ax^3+bx^2+cx, a \neq 0$	Polynomial with Degree 3	$2x^3+3x^2+4x+6$



Metrik Evaluasi Regresi

- Metrik Umum:

- Mean Absolute Error (MAE): Rata-rata kesalahan absolut. $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
- Mean Squared Error (MSE): Rata-rata perbedaan kuadrat antara nilai aktual dan nilai prediksi. $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- R-kuadrat: Proporsi varians yang dijelaskan oleh model. $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

adalah rata-rata dari nilai sebenarnya. Nilai R-kuadrat berkisar dari 0 hingga 1, dengan nilai yang lebih tinggi menunjukkan kecocokan model yang lebih baik dengan data.



Tantangan dalam Regresi

- **Overfitting** : Saat model terlalu rumit dan menangkap *noise*.
- **Multicollinearity** : Korelasi tinggi antara variabel independen.
- **Heteroscedasticity**: Non-constant variance of errors.
- **Solusi Permasalahan**: *Teknik regularisasi, pemilihan fitur, dan transformasi data.*
- Heteroskedastisitas : Varians kesalahan yang tidak konstan.
- Mengatasi Tantangan : Teknik regularisasi, pemilihan fitur, dan transformasi data.



Kesimpulan

- **Summary:** Regression is a powerful tool in supervised learning for predicting continuous outcomes.
- **Key Takeaway:** Understanding different regression techniques and their applications is crucial for effective data analysis and prediction.
- **Next Steps:** Explore advanced regression models and practical implementation with datasets.



**SEE YOU
NEXT WEEK**