



Unsupervised Learning




Course Information


- Course Title : Machine Learning / “*Pembelajaran Mesin*”
- Course Code : ML-IF 101
- Semester : 2024-2025 (1)
- Credits : 3
- Instructor : Dr. Cucun Very Angkoso, MT
- Email : cucunvery@ieee.com
- G-Classroom : (B) dcpe7hi / (D) c4yoy6j

next slide →

Kontrak Kuliah


- Perkuliahan dimulai 07.30 wib ~ Max Jam 08.15wib
- Wajib bergabung G-Classroom
- Penilaian akhir
 - UAS : 30%
 - UTS : 30%
 - Tugas : 40%
- Absensi : threshold 80%, 20% tidak hadir tanpa keterangan
 - $20\% \times 16 \text{ Pertemuan} = 3,6 \sim 4 \text{ pertemuan}$
 - 4 pertemuan tidak hadir tanpa keterangan = Tidak berhak mendapat penilaian akhir.





“Clustering Methods”

K-means, hierarchical clustering, and DBSCAN






Pengelompokan data (Clustering)

- **Clustering** : teknik pembelajaran mesin yang digunakan untuk mengelompokkan data tanpa adanya label kelas yang diketahui sebelumnya. Algoritma *clustering* mencari pola atau kesamaan dalam data untuk membentuk kelompok-kelompok yang koheren.
- Beberapa metode *clustering* yang umum digunakan:
 - K-means clustering: Algoritma ini memilih K titik pusat secara acak sebagai centroid dan kemudian mengelompokkan data berdasarkan jarak terdekat ke centroid.
 - Hierarchical clustering: Metode ini membangun hierarki cluster dengan menggabungkan atau membagi cluster secara berulang.
 - Density-based clustering: Algoritma ini mencari daerah berdensitas tinggi dalam data untuk membentuk cluster.
 - Spectral clustering: Metode ini menggunakan teknik aljabar linear untuk menemukan struktur grafis dalam data dan



Jenis metode clustering



- **Partitioning-Based Clustering**

- Partitioning-based clustering membagi data ke dalam sejumlah cluster yang telah ditentukan sebelumnya. Metode ini mengharuskan pengguna untuk menentukan jumlah cluster (K) sebelum proses dimulai. Algoritma yang paling umum digunakan dalam kategori ini adalah K-Means, yang bekerja dengan mengelompokkan data berdasarkan jarak ke centroid yang dihitung secara iteratif hingga konvergensi tercapai

- **Density-Based Clustering**



- Mengidentifikasi cluster berdasarkan kepadatan data di ruang fitur. Algoritma ini mencari area dengan kepadatan tinggi yang dipisahkan oleh area dengan kepadatan rendah. DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) adalah salah satu algoritma paling populer dalam kategori ini, yang mampu menemukan cluster dengan bentuk arbitrer dan menangani noise serta outlier dengan baik.
- DBSCAN tidak memerlukan penentuan jumlah cluster sebelumnya, karena cluster ditentukan berdasarkan kepadatan data

- **Hierarchical Clustering**

- Membangun struktur hierarki dari cluster, yang dapat divisualisasikan dalam bentuk dendrogram. Metode ini dapat dilakukan secara agglomerative (*bottom-up*) atau divisive (*top-down*)
- Dalam pendekatan agglomerative, setiap titik data dimulai sebagai cluster individu dan secara bertahap digabungkan berdasarkan kedekatan hingga semua data tergabung dalam satu cluster
- *Hierarchical clustering* tidak memerlukan penentuan jumlah cluster sebelumnya dan memberikan wawasan tentang struktur internal data melalui dendrogram



K-means Clustering






Improved K-Means

Algorithm 3 Proposed Method of Initial Cluster Centroids


- 1: Input: A dataset **D** and Number of clusters **K**
- 2: Output: Efficient initial centroids for **K** clusters
- 3: **procedure** PROPOSED METHOD(*Input*)
- 4: All n attributes $a_1, a_2, a_3, \dots, a_n$ of **D** must be numeric. If there is any non-numeric attribute, just convert it to numeric value.
- 5: Apply Principal Component Analysis (PCA) with 2 components to the dataset, **D**.
- 6: Apply percentile for splitting the whole dataset into **K** equal parts based on 1st component.
- 7: Extract the split dataset from primary data by index.
- 8: Calculate the mean of each attribute of the split datasets.
- 9: Take the mean of each dataset as the initial clusters centroids, $C = c_1, c_2, \dots, c_k$, where $c_1, c_2, \dots, c_k$ are the initial centroids for 1st, 2nd, ..., k clusters consecutively.
- 10: Assign the centroids to the k-means clustering algorithm





Hierarchical clustering

- Adalah metode analisis kluster yang berupaya membangun hierarki kluster. Mengelompokkan objek serupa ke dalam kluster, yang memungkinkan identifikasi pola dan hubungan dalam kumpulan data.
- Membuat struktur mirip pohon, yang dikenal sebagai **dendrogram**, yang menggambarkan susunan kluster berdasarkan kesamaannya.
- Metode ini dapat sangat berguna jika jumlah kluster tidak diketahui sebelumnya, karena memungkinkan representasi visual tentang bagaimana titik data dikelompokkan bersama pada berbagai tingkat ketelitian.





Jenis: Aglomeratif vs. Divisif

- Pengelompokan hierarkis dapat dikategorikan menjadi dua jenis utama:
 - Pengelompokan Aglomeratif: Ini adalah pendekatan "bottom-up" di mana setiap titik data dimulai sebagai klasternya sendiri. Algoritma kemudian secara berulang menggabungkan kluster terdekat berdasarkan metrik jarak hingga hanya tersisa satu kluster. Metode ini adalah bentuk pengelompokan hierarkis yang paling umum digunakan.
 - Pengelompokan Divisif: Sebaliknya, ini adalah pendekatan "top-down". Dimulai dengan semua titik data dalam satu kluster dan secara rekursif membagi kluster menjadi kluster yang lebih kecil. Metode ini kurang umum karena kompleksitas dan intensitas komputasinya.



Agglomerative Clustering

- **Langkah 1: Inisialisasi Kluster**

- **Mulai dengan Kluster Individual:**

- Setiap titik data diperlakukan sebagai klasternya sendiri. Misalnya, jika Anda memiliki 10 titik data, awalnya Anda akan memiliki 10 kluster, yang masing-masing berisi satu titik data.

- **Langkah 2: Hitung Jarak**

- **Hitung Jarak Berpasangan:**

- Hitung jarak antara setiap pasangan kluster (Euclidean, jarak Manhattan, atau ukuran lain tergantung pada sifat data).

- **Langkah 3: Gabungkan Kluster Terdekat**

- **Identifikasi Kluster Terdekat:**

- Temukan dua kluster yang paling dekat satu sama lain berdasarkan jarak yang dihitung. Ini dapat dilakukan menggunakan berbagai kriteria keterkaitan, seperti keterkaitan tunggal (jarak minimum), keterkaitan lengkap (jarak maksimum), atau keterkaitan rata-rata.

- Gabungkan Kluster: Gabungkan dua kluster terdekat menjadi kluster baru. Kluster baru ini sekarang berisi semua titik data dari dua kluster yang digabungkan.

- **Langkah 4: Perbarui Matriks Jarak**

- **Hitung Ulang Jarak:**

- Setelah penggabungan, perbarui matriks jarak untuk mencerminkan jarak antara kluster baru dan kluster yang tersisa. Ini melibatkan penghitungan jarak antara kluster baru dan setiap kluster lainnya menggunakan metode yang telah dipilih.

- **Langkah 5: Ulangi Langkah 3 dan 4**

- **Ulangi Hingga Satu Kluster Tersisa:**

- Ulangi proses mengidentifikasi kluster terdekat dan menggabungkannya hingga hanya tersisa satu kluster, yang berisi semua titik data. Proses berulang ini berlanjut hingga jumlah kluster yang diinginkan tercapai atau hingga semua titik digabungkan menjadi satu kluster.

- **Langkah 6: Buat Dendrogram**

- **Visualisasikan Proses Pengelompokan:**

- Setelah pengelompokan selesai, dendrogram dapat dibuat untuk memvisualisasikan hierarki kluster. Dendrogram menunjukkan bagaimana kluster digabungkan pada berbagai tingkat kesamaan, yang memungkinkan interpretasi struktur pengelompokan dengan mudah.



Contoh (*Membuat 2 kluster)

- A(1, 2), B(1, 4), C(1, 0), D(4, 2), E(4, 4), F(4, 0), G(0, 1), H(0, 3), I(0, 5), J(5, 1)

- **Langkah 1: Inisialisasi Kluster**

- Ada 10 kluster

- **Langkah 2: Hitung Jarak**

- Euclidean distance between two points $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$

- A to B: $d(A, B) = \sqrt{(1 - 1)^2 + (4 - 2)^2} = 2$

- A to C: $d(A, C) = \sqrt{(1 - 1)^2 + (2 - 0)^2} = 2$

- A to D: $d(A, D) = \sqrt{(4 - 1)^2 + (2 - 2)^2} = 3$

- A to E: $d(A, E) = \sqrt{(4 - 1)^2 + (4 - 2)^2} = \sqrt{5} \approx 2.24$

- A to F: $d(A, F) = \sqrt{(4 - 1)^2 + (0 - 2)^2} = \sqrt{13} \approx 3.61$

- A to G: $d(A, G) = \sqrt{(1 - 0)^2 + (2 - 1)^2} = \sqrt{2} \approx 1.41$

- A to H: $d(A, H) = \sqrt{(1 - 0)^2 + (2 - 3)^2} = \sqrt{2} \approx 1.41$

- A to I: $d(A, I) = \sqrt{(1 - 0)^2 + (2 - 5)^2} = \sqrt{10} \approx 3.16$

- A to J: $d(A, J) = \sqrt{(1 - 5)^2 + (2 - 1)^2} = \sqrt{17} \approx 4.12$

	A	B	C	D	E	F	G	H	I	J
A	0	2	2	3	2.24	3.61	1.41	1.41	3.16	4.12
B	2	0	4	3	2	4.47	2.24	1.41	3.16	4.12
C	2	4	0	3	4.47	2.24	1.41	3.16	5	5.09
D	3	3	3	0	2	4	3.16	3.16	4.47	1.41
E	2.24	2	4.47	2	0	4	4.47	4.47	5	5.09
F	3.61	4.47	2.24	4	4	0	4.47	4.47	5	5.09
G	1.41	2.24	1.41	3.16	4.47	4.47	0	2	4.47	5.09
H	1.41	1.41	3.16	3.16	4.47	4.47	2	0	2	5.09
I	3.16	3.16	5	4.47	5	5	4.47	2	0	5.09
J	4.12	4.12	5.09	1.41	5.09	5.09	5.09	5.09	5.09	0

Lanjutkan hitung jarak untuk semua data



• Gabungkan Klaster


- Temukan Pasangan Terdekat: Pasangan terdekat adalah (A, G) atau (A, H) atau (B, H) dengan jarak = 1,41.
- Kita pilih menggabungkan A dan G menjadi klaster baru {A, G}.
- Perbarui Matriks Jarak: Hitung ulang jarak dari klaster baru {A, G} ke semua klaster lainnya.
- Ulangi: Terus gabungkan klaster terdekat hingga hanya tersisa 2 klaster.

	A	B	C	D	E	F	G	H	I	J
A	0	2	2	3	2.24	3.61	1.41	1.41	3.16	4.12
B	2	0	4	3	2	4.47	2.24	1.41	3.16	4.12
C	2	4	0	3	4.47	2.24	1.41	3.16	5	5.09
D	3	3	3	0	2	4	3.16	3.16	4.47	1.41
E	2.24	2	4.47	2	0	4	4.47	4.47	5	5.09
F	3.61	4.47	2.24	4	4	0	4.47	4.47	5	5.09
G	1.41	2.24	1.41	3.16	4.47	4.47	0	2	4.47	5.09
H	1.41	1.41	3.16	3.16	4.47	4.47	2	0	2	5.09
I	3.16	3.16	5	4.47	5	5	4.47	2	0	5.09
J	4.12	4.12	5.09	1.41	5.09	5.09	5.09	5.09	5.09	0

Setelah beberapa kali penggabungan, Anda akan mendapatkan 2 klaster.

Misalnya, Anda mungkin menemukan:

Klaster 1: {A, B, C, G, H} **Klaster 2: {D, E, F, I, J}**





**SEE YOU
NEXT WEEK**