



Semester Gasal 2025-2026



Course Information


- Course Title : Machine Learning / “*Pembelajaran Mesin*”
- Course Code : ML-IF 101
- Semester : 2025-2026 (1)
- Credits : 3
- Instructor : Dr. Cucun Very Angkoso, MT
- Email : cucunvery@ieee.com
- G-Classroom : (B) zmgrvfgc / (C) mzybgy6d

next slide



Kontrak Kuliah

- Perkuliahan dimulai 07.30 wib ~ Max Jam 08.15wib
- Wajib bergabung G-Classroom
- Penilaian akhir
 - UAS : 30%
 - UTS : 30%
 - Tugas : 40%
- Absensi : threshold 80%, 20% tidak hadir tanpa keterangan
 - $20\% \times 16 \text{ Pertemuan} = 3,6 \sim 4 \text{ pertemuan}$
 - 4 pertemuan tidak hadir tanpa keterangan = Tidak berhak mendapat penilaian akhir.





Introduction to Data Preprocessing

- Pentingnya preprocessing data dalam pembelajaran mesin.
- Peran kualitas data dalam kinerja model.
- Masalah data umum yang memerlukan praproses:
 - nilai yang hilang,
 - outlier,
 - perbedaan skala, dan
 - fitur yang tidak relevan.

The importance of data preprocessing

- *Preprocessing* data adalah langkah krusial dalam pembelajaran mesin (machine learning) karena kualitas data yang digunakan untuk melatih model sangat mempengaruhi hasil dan kinerja model. Bahkan algoritma terbaik pun tidak dapat memberikan hasil yang optimal jika data yang dimasukkan berkualitas rendah





Contoh data :

1. Missing Values (Nilai yang Hilang):

- Kolom **Age**, **Salary**, **Experience**, **Department**, dan **Satisfaction_Score** mengandung nilai yang hilang (NaN).

2. Categorical Data (Data Kategoris):

- Kolom **Department** adalah data kategoris yang perlu di-encode (misalnya, melalui one-hot encoding atau label encoding) sebelum dimasukkan ke dalam model pembelajaran mesin.

3. Inconsistent Data (Data Tidak Konsisten):

- Tidak ada masalah besar terkait inkonsistensi di dataset ini, tetapi perlu diperhatikan lebih lanjut dalam preprocessing untuk memastikan tidak ada duplikasi atau kesalahan input lainnya.

4. Outliers:

- Meskipun outliers belum dianalisis di sini, rentang data **Age**, **Salary**, dan **Experience** perlu diperiksa apakah ada nilai ekstrem yang perlu ditangani.

Age	Salary	Experience	Department	Satisfaction_Score
25	50000	2	HR	4.5
NaN	60000	10	Finance	4
35	NaN	7	HR	5
45	80000	15	NaN	3.5
NaN	45000	NaN	IT	NaN



Menentukan kualitas data

1. Kelengkapan Data (*Completeness*)

- Seberapa lengkap data yang tersedia untuk setiap fitur atau variabel. Data yang memiliki banyak nilai yang hilang (*missing values*) dapat menyebabkan model gagal mengenali pola dengan baik.
 - **Evaluasi:**
 - Identifikasi missing values di setiap kolom.
 - Tentukan persentase data yang hilang dan apakah itu berpengaruh pada kualitas analisis.
 - **Tindakan:**
 - Imputasi nilai yang hilang menggunakan metode seperti mean, median, modus, atau algoritma yang lebih kompleks seperti KNN atau regresi.
 - Hapus baris/kolom jika jumlah data hilang terlalu banyak dan tidak signifikan untuk analisis.
 - **Flagging:** Membuat fitur baru yang menunjukkan apakah nilai tersebut hilang atau tidak.



Flagging

- **Dataset Awal:**

Umur	Pendapatan	Status_Pekerjaan
25	5000	Karyawan
30	6000	NULL
22	4500	Mahasiswa
28	7000	NULL

- Membuat kolom baru **Status_Pekerjaan_Hilang**:

Umur	Pendapatan	Status_Pekerjaan	Status_Pekerjaan_Hilang
25	5000	Karyawan	0
30	6000	NULL	1
22	4500	Mahasiswa	0
28	7000	NULL	1



Menentukan kualitas data

2. Kebersihan Data (*Cleanliness*)

- Apakah data bebas dari noise, outliers, kesalahan input, dan inkonsistensi (misalnya, duplikasi, format yang tidak konsisten).
- **Evaluasi:**
 - Analisis deskriptif untuk mendeteksi outliers (menggunakan Z-score atau IQR).
 - Cek konsistensi format data (misalnya, tanggal dalam format yang berbeda, penulisan kategori yang tidak seragam).
- **Tindakan:**
 - Hapus duplikasi.
 - Koreksi format yang tidak konsisten.
 - Lakukan pengolahan terhadap outliers berdasarkan aturan bisnis atau analisis statistik.



Menentukan kualitas data

3. Keakuratan Data (*Accuracy*)

- Seberapa benar atau sesuai data yang dimiliki dengan kenyataan. Jika ada kesalahan dalam pengumpulan data (misalnya, pengukuran yang salah), model yang dihasilkan akan kurang akurat.
- **Evaluasi:**
 - Bandingkan data dengan sumber referensi eksternal atau data yang telah tervalidasi.
 - Identifikasi data yang tidak masuk akal atau tidak logis (misalnya, usia negatif).
- **Tindakan:**
 - Perbaiki kesalahan data jika ada sumber yang akurat untuk membandingkan.
 - Tandai atau hapus data yang tidak valid jika tidak dapat diperbaiki.



Menentukan kualitas data

4. Konsistensi Data (*Consistency*)

- Apakah data di berbagai sumber atau dalam dataset yang sama bersifat konsisten. Inkonsistensi terjadi jika variabel yang sama memiliki arti yang berbeda di berbagai tempat atau format yang berubah-ubah.
- **Evaluasi:**
 - Cek apakah satu entitas yang sama memiliki nilai yang berbeda di beberapa tempat (misalnya, kode produk yang sama dengan nama berbeda).
 - Cek apakah ada variabel yang berubah format dalam dataset yang sama.
- **Tindakan:**
 - Gabungkan atau standarkan format dan nilai yang berbeda namun merujuk pada satu hal yang sama.



Menentukan kualitas data

5. Keberagaman Data (Diversity)

- Seberapa beragam dan representatif data yang dimiliki terhadap populasi target. Dataset yang tidak beragam dapat menyebabkan model bias.
- **Evaluasi:**
 - Cek distribusi kelas pada variabel target untuk mendeteksi ketidakseimbangan kelas.
 - Analisis variasi fitur untuk memastikan representasi dari seluruh populasi.
- **Tindakan:**
 - Jika data tidak seimbang (misalnya, dalam klasifikasi), pertimbangkan metode oversampling atau undersampling untuk menangani imbalance data.
 - Pastikan bahwa data mencakup variasi yang diperlukan untuk model agar tidak bias.



Menentukan kualitas data

6. Relevansi Data (*Relevance*)

- **Definisi:** Seberapa relevan atau penting setiap fitur untuk memprediksi target variabel. Data yang tidak relevan atau tidak berguna bisa menambah noise pada model.
- **Evaluasi:**
 - Gunakan teknik seleksi fitur seperti **Variance Threshold**, **Univariate Selection**, **Recursive Feature Elimination (RFE)**, atau **PCA** untuk menentukan fitur yang paling relevan.
 - Analisis korelasi antara fitur dan target.
- **Tindakan:**
 - Hilangkan fitur yang tidak relevan untuk mengurangi kompleksitas model.
 - Lakukan feature engineering untuk menciptakan fitur baru yang lebih relevan.



Menentukan kualitas data

7. Tingkat Redundansi (Redundancy)

- Apakah terdapat fitur yang mengandung informasi yang sama atau sangat mirip. Data yang sangat redundant dapat menyebabkan overfitting atau memperlambat proses pelatihan model.
- **Evaluasi:**
 - Gunakan teknik seperti korelasi antar-fitur untuk mendeteksi fitur yang terlalu mirip.
 - Lakukan analisis kolinearitas, terutama untuk algoritma yang sensitif terhadap multikolinearitas seperti regresi linear.
- **Tindakan:**
 - Hapus atau gabungkan fitur yang redundant.
 - Gunakan teknik reduksi dimensi seperti **Principal Component Analysis (PCA)** untuk mengatasi masalah redundansi.



Menentukan kualitas data

8. Distribusi Data (*Data Distribution*)

- Distribusi data yang baik harus sesuai dengan asumsi algoritma yang digunakan. Misalnya, beberapa algoritma bekerja lebih baik jika data terdistribusi secara normal.
- **Evaluasi:**
 - Gunakan visualisasi seperti histogram atau box plot untuk melihat distribusi data.
 - Cek skewness dan kurtosis.
- **Tindakan:**
 - Lakukan transformasi data seperti Standard Scaler, Normalisasi Min-Max, Standarisasi (Z-Score Normalization), Decimal Scaling, Power Transformation, dll untuk menormalkan distribusi data jika diperlukan.



Data Cleaning

2.1 Handling Missing Data

- **Types of Missing Data:**

- *Missing Completely at Random (MCAR)* : Data hilang secara acak dan tidak terkait dengan variabel lain atau nilai yang hilang itu sendiri.
- *Missing at Random (MAR)*: Data hilang tetapi dapat diprediksi dari variabel lain yang ada dalam dataset.
- *Missing Not at Random (MNAR)*: Data hilang karena alasan yang berkaitan dengan nilai yang hilang itu sendiri.

- **Techniques to Handle Missing Data:**

- **Removal (Listwise or Pairwise deletion)**: Removing rows or columns with missing values. (MCAR)
- **Imputation**: Replacing missing values with: (MAR)
 - Mean, median, or modus.
 - More advanced techniques like k-nearest neighbors (KNN) imputation or multiple imputations.
- **Predictive Models**: Using machine learning models to predict missing values. (MNAR)
- **Analisis Sensitivitas** (MNAR)
- **Modeling Spesifik** (MNAR)



Contoh data



ID	Nama	Umur	Pendapatan (USD)	Status Pernikahan	Nilai Kesehatan
1	Ali	25	50000	Menikah	8
2	Budi	30	NULL	Lajang	7
3	Citra	22	45000	Menikah	9
4	Dedi	35	60000	NULL	6
5	Evi	28	52000	Lajang	5
6	Fani	40	70000	Menikah	10
7	Gita	29	48000	Lajang	NULL
8	Hadi	31	55000	Menikah	8



1. Kolom "Pendapatan (USD)"

- Jenis: Kemungkinan MAR (Missing at Random), karena data pendapatan Budi hilang sedangkan data lainnya lengkap.
- Rekomendasi Penanganan:
 - Imputasi Median: Gunakan median dari kolom "Pendapatan" untuk mengisi nilai yang hilang, karena pendapatan seringkali tidak terdistribusi normal dan median dapat lebih representatif daripada rata-rata.
 - Imputasi Berbasis Model: Jika ada korelasi kuat dengan variabel lain, gunakan regresi atau KNN untuk memperkirakan nilai yang hilang.

2. Kolom "Status Pernikahan"

- Jenis: Kemungkinan MCAR, karena hanya satu nilai yang hilang dan tampaknya tidak ada pola yang jelas.
- Rekomendasi Penanganan:
 - Mode Imputation: Isi nilai yang hilang dengan modus (nilai yang paling sering muncul) dari kolom "Status Pernikahan". Ini adalah pendekatan yang baik untuk data kategorikal dengan MCAR.

3. Kolom "Nilai Kesehatan"

- Jenis: Kemungkinan MAR, karena nilai kesehatan Gita hilang dan mungkin ada hubungan dengan usia atau faktor lainnya.
- Rekomendasi Penanganan:
 - Imputasi Mean: Jika data terdistribusi normal, menggunakan rata-rata adalah pilihan yang baik.
 - Imputasi Berbasis Model: Gunakan regresi berganda yang mempertimbangkan variabel lain seperti "Umur" dan "Pendapatan" untuk mengisi nilai yang hilang, jika terdapat pola yang dapat dimanfaatkan.

K-Nearest Neighbors (KNN)



```
1 FUNCTION KNN Imputation(data, K):
2     # data: DataFrame yang berisi data dengan nilai yang hilang
3     # K: Jumlah tetangga terdekat yang akan digunakan
4
5     # 1. Pra-pemrosesan Data
6     data_normalized = Normalize(data) # Normalisasi data jika diperlukan
7     data_encoded = OneHotEncode(data_normalized) # Mengonversi kolom kategorikal ke numerik
8
9     # 2. Loop untuk setiap baris dalam data
10    FOR each row in data_encoded:
11        IF row has missing values:
12            # 3. Hitung jarak ke semua baris lainnya
13            distances = []
14            FOR each other_row in data_encoded:
15                IF other_row is not row:
16                    distance = CalculateEuclideanDistance(row, other_row)
17                    distances.append((other_row, distance))
18
19            # 4. Urutkan jarak dan ambil K tetangga terdekat
20            distances.sort(by=distance)
21            nearest_neighbors = distances[0:K]
22
23            # 5. Hitung nilai imputasi
24            IF missing value is numeric:
25                imputed_value = CalculateMean([neighbor.value for neighbor in nearest_neighbors])
26            ELSE IF missing value is categorical:
27                imputed_value = CalculateMode([neighbor.value for neighbor in nearest_neighbors])
28
29            # 6. Isi nilai yang hilang dengan nilai imputasi
30            row.missing_value = imputed_value
31
32    RETURN data_encoded # Kembalikan data yang telah diimputasi
```




Contoh data



ID	Nama	Umur	Pendapatan (USD)	Status Pernikahan	Nilai Kesehatan
1	Ali	25	50000	Menikah	8
2	Budi	30	NULL	Lajang	7
3	Citra	22	45000	Menikah	9
4	Dedi	35	60000	NULL	6
5	Evi	28	52000	Lajang	5
6	Fani	40	70000	Menikah	10
7	Gita	29	48000	Lajang	NULL
8	Hadi	31	55000	Menikah	8

Hitung “Nilai Kesehatan” Gita menggunakan KNN



Data Cleaning

2.2 Handling Outliers

- Methods to detect outliers (Z-score, IQR).

1. Hitung rata-rata (μ) dan deviasi standar (σ) dari dataset.
2. Hitung Z-Score untuk setiap nilai dalam dataset.
3. Tentukan ambang batas untuk mendeteksi outlier. Umumnya, nilai Z-Score di atas 3 atau di bawah -3 dianggap sebagai outlier.

$$Z = \frac{X - \mu}{\sigma}$$

- IQR



$$IQR = Q3 - Q1$$

- **Q1** adalah nilai yang membagi 25% data terendah,
- **Q3** adalah nilai yang membagi 75% data terendah.

Langkah-langkah:

1. Hitung Q1 dan Q3 dari dataset.
2. Hitung IQR.
3. Tentukan batas bawah dan batas atas:
 - Batas bawah = $Q1 - 1.5 \times IQR$
 - Batas atas = $Q3 + 1.5 \times IQR$
4. Nilai yang berada di luar batas ini dianggap sebagai outlier.

ID	Umur	Pendapatan (USD)
1	25	50000
2	30	52000
3	22	48000
4	35	60000
5	28	55000
6	40	700000
7	29	49000
8	31	53000

Contoh data

- Strategi untuk menangani outlier: Menghapus, membatasi, atau mentransformasi.



Data Transformation

• Normalization

- Rescaling data to a fixed range.
- **When to use it:** Suitable for algorithms that rely on distance measures (e.g., KNN, neural networks).
- **Common Normalization Techniques:**
 - **Min-Max Scaling:** Formula: $X' = \frac{X - X_{min}}{X_{max} - X_{min}} X$
 - **Max Abs Scaling:** Divides each value by the maximum absolute value of the data.



Data Transformation

- **Standardization**

- Rescaling data to have a mean of 0 and standard deviation of 1.
- **When to use it:** Useful for algorithms that assume normally distributed data (e.g., SVM, logistic regression).
- **Formula for Standardization Z-Score Normalization :**
$$Z = \frac{X - \mu}{\sigma}$$
- where μ is the mean and σ (sigma) is the standard deviation.

- **Logarithmic Scaling and Other Transformations**

- Use for handling skewed data (e.g., log, square root, box-cox transformations).



Feature Scaling

- **Penskalaan fitur** adalah teknik untuk menstandarisasi rentang variabel independen atau fitur data. Hal ini penting untuk algoritme yang menghitung jarak antara titik data, seperti pengelompokan K-Means dan K-Nearest Neighbors.
- **Standardization:** Mirip dengan normalisasi Z-score, teknik ini mengubah data agar memiliki rata-rata 0 dan deviasi standar 1.
- **Robust Scaling:** Menggunakan median dan rentang interkuartil untuk penskalaan, sehingga kuat terhadap outlier.

$$X_{scaled} = \frac{(X - median)}{IQR}$$

IQR adalah rentang interkuartil.



**SEE YOU
NEXT WEEK**